

Mon Projet Data Science

Projet Fil Rouge Data Science - Sujet Libre

Étudiant(e) 1 : [Blain Antoine] Étudiant(e) 2 : [Martin Evan] Étudiant(e) 3 : [Pecontal Corentin]

2026-05-19

Table of contents

1	Introduction et Contexte Métier	2
1.1	Contexte du Projet	3
1.2	Objectif Analytique	3
2	Acquisition et Préparation des Données (Data Wrangling)	4
2.1	Chapitre 1 : Acquisition Multi-Sources	4
3	 Étape 1 : Acquisition des Données & Multi-Sources (Squelette Étudiant)	4
3.0.a	1. Initialisation de l'environnement	4
3.0.b	2. Chargement de la source de données principale	4
3.1	→ À voir si on ajoute d'autres données	4
3.1.a	3. Intégration de données secondaires (Multi-Sources)	4
3.1.b	4. Fusion des sources (Optionnel)	4
3.1.c	5. Consignation des données d'entrée brutes	4
3.2	Chapitre 2 : Nettoyage et Préparation (Wrangling)	4
4	 Étape 2 : Préparation & Nettoyage de Données (Data Wrangling) (Squelette Étudiant) ...	4
4.0.a	1. Initialisation et imports	5
4.0.b	2. Chargement du dataset brut et Audit Initial	5
4.0.c	3. Uniformisation des Formats de Dates	5
4.0.d	4. Identification et Filtrage des Valeurs Aberrantes (Outliers)	5
5	On retire les colonnes qui ne seront pas pertinentes et les lignes n'impliquant aucun paiement	5
5.0.a	6. Sauvegarde des données propres	5
6	Visualisation Multidimensionnelle (Insights)	5
6.1	Chapitre 3 : Travaux Pratiques d'Exploration Visuelle	5
7	 Étape 4 : Visualisation Multidimensionnelle (Squelette Étudiant)	5
7.0.a	1. Préparation de l'environnement	6
7.0.b	2. Chargement du dataset enrichi	6
7.0.c	3. Tracés et analyses graphiques	6
8	Analyse Exploratoire des Données (EDA)	6

8.1	Chapitre 4 : Travaux Pratiques d'Exploration (EDA)	6
9	 Étape 3 : Analyse Exploratoire des Données (EDA) (Squelette Étudiant)	6
9.0.a	1. Préparation de l'environnement	6
9.0.b	2. Chargement des données nettoyées	6
9.0.c	3. Statistiques Descriptives	6
9.0.d	4. Ingénierie de variables (Feature Engineering)	6
9.0.e	5. Analyse des Corrélations	7
10	Modélisation et Apprentissage	7
10.1	Chapitre 5 : Travaux Pratiques de Modélisation (ML & DL)	7
11	 Étape 5 : Modélisation (Machine Learning & Deep Learning) (Squelette Étudiant)	7
11.0.a	1. Préparation de l'environnement	7
11.0.b	2. Modélisation Tabulaire (Machine Learning)	7
11.0.c	3. Modélisation Vision / Deep Learning (CNN & TensorFlow)	8
12	Évaluation Métrique et Validation	8
12.1	Chapitre 6 : Travaux Pratiques d'Évaluation & Robustesse	8
13	 Étape 6 : Évaluation Métrique & Robustesse (Squelette Étudiant)	8
13.0.a	1. Préparation de l'environnement	8
13.0.b	2. Évaluation du modèle Tabulaire	8
13.0.c	3. Protocole de Validation Croisée (Out-of-Fold / Chronologique)	8
14	Data Storytelling et Communication	8
14.1	Chapitre 7 : Travaux Pratiques de Storytelling	8
15	 Étape 7 : Data Storytelling & Communication (Squelette Étudiant)	8
15.0.a	1. Préparation de l'environnement	8
15.0.b	2. Synthèse métier et Storytelling	8
15.0.c	3. Visualisation Interactive (Plotly)	9
15.1	Présentation des Résultats (Livrables Interactifs)	9
15.1.a	 Diaporama de Soutenance (RevealJS)	9
15.1.b	 Exemple de Dashboard Dynamique (OJS / Plotly)	9
16	Utilisation de l'Intelligence Artificielle	10
16.1	Cartographie de l'utilisation de l'IA	10
16.2	Principes de Rigueur et Responsabilité	10
	Bibliographie	10
	Bibliography	11

1 Introduction et Contexte Métier

*À rédiger par les étudiants : Présentez ici le contexte global de votre projet, la problématique métier que vous cherchez à résoudre, les questions scientifiques soulevées et les opportunités d'aide à la décision sur la base de vos données. Dans le cadre de ce projet, nous travaillons sur une base de données artificielle générée en 2024 reproduisant des trajets Uber et les informations associées aux courses.

L'objectif principal de cette étude est de déterminer et prédire le prix d'une course à partir de plusieurs variables, notamment le lieu de prise en charge du client, la distance parcourue ainsi que d'autres caractéristiques présentes dans les données.

Plusieurs questions se posent :

- Quels sont les paramètres ayant le plus d'impact sur le prix d'une course ?
- Existe-t-il une relation forte entre la distance et le tarif ?
- Le lieu de prise en charge influence-t-il significativement le prix final ?
- Peut-on construire un modèle prédictif fiable à partir des données disponibles ?

Afin de répondre à ces questions, différentes étapes seront réalisées : préparation et nettoyage des données, analyse, visualisation des tendances ETC.

*

1.1 Contexte du Projet

À rédiger par les étudiants — Pistes de réflexion :

- *Quels sont les objectifs globaux et le domaine d'étude de votre projet ?*
- *En quoi ce sujet de recherche est-il pertinent et stratégique ?*
- *Pourquoi l'analyse quantitative de ce jeu de données est-elle indispensable pour répondre à votre problématique ?*

Ce projet s'inscrit dans le domaine de la data science appliquée à la mobilité du service UBER. Les plateformes de VTC exploitent de grandes quantités de données afin d'optimiser leurs services, améliorer l'expérience utilisateur et adapter leurs stratégies tarifaires.

Ce sujet est particulièrement pertinent car la prédiction des prix représente un enjeu important pour les entreprises de transport. Une meilleure compréhension des facteurs influençant les tarifs permet d'optimiser les revenus et de proposer des prix cohérents aux différents utilisateurs.

L'analyse quantitative des données est essentielle pour répondre à cette problématique. L'étude statistique et l'exploitation des données permettent d'identifier les tendances, de mesurer l'impact des différentes variables et de construire des modèles prédictifs fiables. Les résultats obtenus peuvent ainsi servir d'aide pour améliorer les stratégies de tarification.

1.2 Objectif Analytique

À rédiger par les étudiants — Pistes de réflexion :

- *Quelles sont les variables cibles principales et la tâche globale de modélisation (classification, régression, clustering, etc.) ?*
- *Comment le couplage de données multi-sources et l'intégration de différents types de données (tabulaires, images, signaux, etc.) enrichissent-ils l'analyse ?*
- *Quels sont les livrables analytiques attendus pour répondre à votre problématique et guider les prises de décisions ?*

[Rédiger votre paragraphe d'objectifs ici]

2 Acquisition et Préparation des Données (Data Wrangling)

Le succès de tout projet de Data Science repose sur la qualité de la préparation des données [1]. Cette section documente l'audit de qualité et les étapes de nettoyage appliquées à vos jeux de données bruts.

2.1 Chapitre 1 : Acquisition Multi-Sources

3 📦 Étape 1 : Acquisition des Données & Multi-Sources (Squelette Étudiant)

Cette étape correspond au premier chapitre du pipeline de Data Science. L'objectif est d'identifier, d'importer et de consolider vos jeux de données bruts issus de différentes sources (fichiers CSV locaux, requêtes API, bases de données, etc.).

3.0.a 1. Initialisation de l'environnement

3.0.b 2. Chargement de la source de données principale

Chargement de notre jeu de données grâce à un fichier CSV stocké dans `data/raw/`

3.1 → À voir si on ajoute d'autres données

3.1.a 3. Intégration de données secondaires (Multi-Sources)

À COMPLÉTER PAR L'ÉTUDIANT : Mettez en place la récupération de vos données complémentaires (par exemple, appels d'API fictifs ou réels, données météo, géographiques, ou financiers complémentaires).

3.1.b 4. Fusion des sources (Optionnel)

À COMPLÉTER PAR L'ÉTUDIANT : Associez vos différentes sources de données en utilisant des jointures (`pd.merge`) pertinentes.

3.1.c 5. Consignation des données d'entrée brutes

Sauvegardez l'état brut de vos données d'entrée pour la suite du pipeline.

3.2 Chapitre 2 : Nettoyage et Préparation (Wrangling)

4 🧹 Étape 2 : Préparation & Nettoyage de Données (Data Wrangling) (Squelette Étudiant)

Cette étape correspond au deuxième chapitre du projet. L'objectif est d'effectuer un audit de qualité de vos données brutes, puis de mettre en œuvre un nettoyage rigoureux à l'aide de votre package personnalisé `src.data_clean`.

4.0.a 1. Initialisation et imports

4.0.b 2. Chargement du dataset brut et Audit Initial

On charge nos données et inspectez la qualité du dataset avec `.info()`, `.isnull().sum()` et `.duplicated().sum()`

4.0.c 3. Uniformisation des Formats de Dates

Uniformisez la colonne temporelle on fait un Regex pour voir si un Date et l'heure est incorrecte ou mauvais format

On crée une colonne avec la Date et l'heure au format `DateTime`

4.0.d 4. Identification et Filtrage des Valeurs Aberrantes (Outliers)

À COMPLÉTER PAR L'ÉTUDIANT : Identifiez les anomalies physiques et utilisez votre fonction `dc.handle_outliers` pour transformer ces valeurs aberrantes en NaNs.

On vérifie la correspondance entre Booking ID et colonnes Cancelled Rides

On vérifie s'il y a des paiements en fonction des statuts

5 On retire les colonnes qui ne seront pas pertinentes et les lignes n'impliquant aucun paiement

On n'a plus aucun NaN dans la base (ils étaient tous dans les colonnes qu'on a supprimées)

On se fait un aperçu des données, notamment pour chercher la présence d'outliers

5.0.a 6. Sauvegarde des données propres

Enregistrez vos données de base nettoyées dans le répertoire `data/processed/`.

6 Visualisation Multidimensionnelle (Insights)

Nous présentons ici les résultats visuels clés permettant de dégager des insights exploitables pour les décideurs, en s'appuyant sur notre module `src/utils_viz.py`.

6.1 Chapitre 3 : Travaux Pratiques d'Exploration Visuelle

7 Étape 4 : Visualisation Multidimensionnelle (Squelette Étudiant)

Cette étape correspond au quatrième chapitre du cours. L'objectif est de concevoir des représentations visuelles premium pour identifier des tendances et insights clés à l'aide de votre package personnalisé de tracé `src.utils_viz`.

7.0.a 1. Préparation de l'environnement

7.0.b 2. Chargement du dataset enrichi

7.0.c 3. Tracés et analyses graphiques

7.0.c.a A. Évolution des tendances dans le temps

À COMPLÉTER PAR L'ÉTUDIANT : Tracez les tendances globales à l'aide de la fonction `uv.plot_generic_trends`.

7.0.c.b B. Carte de chaleur des corrélations

À COMPLÉTER PAR L'ÉTUDIANT : Visualisez graphiquement les corrélations de Pearson à l'aide de `uv.plot_correlation_matrix`.

7.0.c.c C. Nuage de points bivarié

À COMPLÉTER PAR L'ÉTUDIANT : Générez une analyse graphique bivariée en utilisant `uv.plot_bivariate_scatter`.

8 Analyse Exploratoire des Données (EDA)

Dans cette section, nous analysons les relations statistiques fondamentales qui régissent votre domaine d'étude au sein du jeu de données.

8.1 Chapitre 4 : Travaux Pratiques d'Exploration (EDA)

9 Étape 3 : Analyse Exploratoire des Données (EDA) (Squelette Étudiant)

Cette étape correspond au troisième chapitre du cours. L'objectif est d'explorer et de résumer les propriétés statistiques fondamentales de vos données et de réaliser du **Feature Engineering** pour enrichir vos modèles.

9.0.a 1. Préparation de l'environnement

9.0.b 2. Chargement des données nettoyées

9.0.c 3. Statistiques Descriptives

À COMPLÉTER PAR L'ÉTUDIANT : Générez les résumés statistiques globaux et par groupes/catégories de votre jeu de données.

9.0.d 4. Ingénierie de variables (Feature Engineering)

À COMPLÉTER PAR L'ÉTUDIANT : Appliquez la fonction `feature_engineering` de `src.data_clean` pour extraire des indicateurs temporels de base, et ajoutez d'autres variables dérivées complexes adaptées à votre problématique.

9.0.e 5. Analyse des Corrélations

À COMPLÉTER PAR L'ÉTUDIANT : Analysez la matrice des corrélations des caractéristiques numériques à l'aide de Pandas.

10 Modélisation et Apprentissage

Le pipeline complet intègre à la fois la branche analytique tabulaire (Machine Learning) et la branche d'analyse visuelle ou de signaux complexes (Deep Learning CNN) :

```
graph TD
    A[Données Brutes Multi-Sources CSV/API] -->|Formatage & Alignement| B(data_clean.clean_dates)
    C[Données Externes Complémentaires] -->|Imputation & Interpolation| D(data_clean.impute_missing_values)
    B & D -->|Gestion Outliers| E[Jeu de données Propre & Fusionné]
    E -->|Extraction Temporelle/Caractéristiques| F[Feature Engineering]
    F -->|Splits Temporels ou Stratifiés| G[Modèle Machine Learning Tabulaire]
    H[Flux Multimédias Réels Images/Signaux] -->|Prétraitement d'images/signaux| I[Réseau Convolutif CNN TensorFlow]
    G -->|Prédictions de la Problématique Métier| J[Livrables & Aide à la Décision]
    I -->|Détection de Motifs Complexes| J

    style E fill:#e0f2fe,stroke:#0284c7,stroke-width:2px
    style J fill:#f0fdf4,stroke:#16a34a,stroke-width:2px
    style G fill:#fef3c7,stroke:#d97706,stroke-width:2px
    style I fill:#fef3c7,stroke:#d97706,stroke-width:2px
```

10.1 Chapitre 5 : Travaux Pratiques de Modélisation (ML & DL)

11 Étape 5 : Modélisation (Machine Learning & Deep Learning) (Squelette Étudiant)

Cette étape correspond au cinquième chapitre du cours. L'objectif est d'implémenter d'une part un modèle de Machine Learning tabulaire (ex: RandomForest) et d'autre part un réseau de neurones convolutif (CNN) sous TensorFlow pour traiter des images ou signaux complexes.

11.0.a 1. Préparation de l'environnement

11.0.b 2. Modélisation Tabulaire (Machine Learning)

À COMPLÉTER PAR L'ÉTUDIANT : Entraînez un modèle d'apprentissage supervisé (ex: forêt aléatoire) sur les caractéristiques extraites de votre jeu de données.

11.0.c 3. Modélisation Vision / Deep Learning (CNN & TensorFlow)

À COMPLÉTER PAR L'ÉTUDIANT : Pour des motifs complexes (images/signaux), mettez en place un réseau convolutif (Conv2D, Pooling, Dense) pour classifier ou enrichir vos prédictions.

12 Évaluation Métrique et Validation

12.1 Chapitre 6 : Travaux Pratiques d'Évaluation & Robustesse

13 Étape 6 : Évaluation Métrique & Robustesse (Squelette Étudiant)

Cette étape correspond au sixième chapitre du cours. L'objectif est de mettre en place un protocole d'évaluation rigoureux (splits d'évaluation adaptés) et de calculer les métriques clés de performance pour valider scientifiquement la qualité de vos modèles.

13.0.a 1. Préparation de l'environnement

13.0.b 2. Évaluation du modèle Tabulaire

À COMPLÉTER PAR L'ÉTUDIANT : Calculez et interprétez les métriques d'erreur sur vos prédictions (MAE, RMSE, R^2).

13.0.c 3. Protocole de Validation Croisée (Out-of-Fold / Chronologique)

À COMPLÉTER PAR L'ÉTUDIANT : Décrivez et codez (ou documentez) une stratégie de validation croisée adaptée au comportement temporel de vos données pour valider la robustesse de votre modèle sans fuite d'information.

14 Data Storytelling et Communication

14.1 Chapitre 7 : Travaux Pratiques de Storytelling

15 Étape 7 : Data Storytelling & Communication (Squelette Étudiant)

Cette étape correspond au septième et dernier chapitre de data science. L'objectif est de synthétiser vos résultats pour des profils métiers ou décideurs et de proposer des visualisations interactives ou dynamiques pour valoriser vos conclusions.

15.0.a 1. Préparation de l'environnement

15.0.b 2. Synthèse métier et Storytelling

À COMPLÉTER PAR L'ÉTUDIANT : Traduisez vos métriques techniques en impacts stratégiques (par exemple, gains financiers, réduction de coûts, amélioration de la sécurité, etc.).

15.0.c 3. Visualisation Interactive (Plotly)

À COMPLÉTER PAR L'ÉTUDIANT : Générez un graphique interactif (par exemple en utilisant Plotly ou des éléments OJS dans le document final) pour permettre aux décideurs d'interagir dynamiquement avec vos données.

15.1 Présentation des Résultats (Livrables Interactifs)

15.1.a Diaporama de Soutenance (RevealJS)

Ci-dessous est intégré le squelette de votre diaporama de soutenance RevealJS. Utilisez-le pour présenter votre démarche aux décideurs de façon professionnelle.

15.1.b Exemple de Dashboard Dynamique (OJS / Plotly)

Voici un exemple minimal de code montrant comment intégrer un graphique dynamique contrôlé par un composant d'interface utilisateur en Observable JS (OJS).

```
//| echo: true
// Boutons de sélection interactifs OJS
viewof selectedCategory = Inputs.select(["Toutes", "A", "B", "C"], {value:
"Toutes", label: "Filtrer par Catégorie :"})
```

```
//| echo: false
// Données simulées réactives
data = [
  {timestamp: "2026-05-18T00:00:00Z", value: 10.5, category: "A"},
  {timestamp: "2026-05-18T02:00:00Z", value: 12.1, category: "A"},
  {timestamp: "2026-05-18T04:00:00Z", value: 14.7, category: "A"},
  {timestamp: "2026-05-18T05:00:00Z", value: 15.2, category: "A"},
  {timestamp: "2026-05-18T06:00:00Z", value: 16.0, category: "B"},
  {timestamp: "2026-05-18T07:00:00Z", value: 18.3, category: "B"},
  {timestamp: "2026-05-18T09:00:00Z", value: 21.5, category: "B"},
  {timestamp: "2026-05-18T10:00:00Z", value: 22.0, category: "B"},
  {timestamp: "2026-05-18T12:00:00Z", value: 25.4, category: "C"},
  {timestamp: "2026-05-18T13:00:00Z", value: 26.1, category: "C"},
  {timestamp: "2026-05-18T15:00:00Z", value: 28.9, category: "C"},
  {timestamp: "2026-05-18T16:00:00Z", value: 30.2, category: "C"}
]

// Filtrage réactif de la donnée
filteredData = selectedCategory === "Toutes"
  ? data
  : data.filter(d => d.category === selectedCategory)

// Tracé interactif avec la librairie Plotly
```

```

Plotly.newPlot('dynamic-chart', [{
  x: filteredData.map(d => d.timestamp),
  y: filteredData.map(d => d.value),
  type: 'scatter',
  mode: 'lines+markers',
  marker: {color: '#1A73E8', size: 8},
  line: {shape: 'spline', color: '#1A73E8', width: 3}
}], {
  title: 'Évolution Dynamique des Valeurs (Filtrée)',
  margin: {t: 50, b: 50, l: 50, r: 50},
  paper_bgcolor: 'rgba(0,0,0,0)',
  plot_bgcolor: 'rgba(0,0,0,0)',
  xaxis: {gridcolor: '#E5E7EB'},
  yaxis: {gridcolor: '#E5E7EB'}
})

```

16 Utilisation de l'Intelligence Artificielle

Dans une démarche de transparence scientifique et académique, cette section détaille la manière dont les outils d'Intelligence Artificielle (IA) générative ont été intégrés tout au long de la réalisation de ce projet.

16.1 Cartographie de l'utilisation de l'IA

Outil d'IA	Cas d'usage (Pourquoi ?)	Méthode d'utilisation (Comment ?)	Rôle et Validation Humaine
[Outil d'IA]	[À compléter par les étudiants]	[À compléter par les étudiants]	[À compléter par les étudiants]

16.2 Principes de Rigueur et Responsabilité

1. **Responsabilité intellectuelle** : L'équipe assume l'entière responsabilité des analyses, des choix de modèles et des conclusions présentées dans ce rapport.
 2. **Lutte contre les hallucinations** : Chaque suggestion technique a fait l'objet d'une validation empirique.
 3. **Protection des données** : Aucun jeu de données confidentiel ou sensible n'a été soumis à des modèles tiers en ligne.
-

Bibliographie

Bibliography

- [1] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*. O'Reilly Media, 2020.